DSM 5001 Veri Biliminde Olasılık ve İstatistik
2. Ödevi

Tarık Tuna Taşaltı

2024/12/04

İçindekiler

1 Güney Asya Nüfus ve Göç Verileri (1960-2023) 2
1.1 **Sütunlar** . . . 2
1.2 **Veri Setine Erişim** . . . 2
1.3 **Veri Seti Özet Bilgiler** . . . 2

2 Veri Seti Çarpıklık Analizi 3

3 Çarpıklık İçin Uygun Dönüşümün Bulunması 4

4 Dönüşüm Sonrası Veri Görselleştirmesi 5
4.1 Year Kolonu . . . 6
4.2 Total Population Kolonu . . . 7
4.3 Net Migration Kolonu . . . 8

5 Goodnes of Fit Testleri 9
5.1 Year Kolonunun Normallik Sınaması . . . 9
5.2 TotalPopulation Kolonunun Normallik Sınaması . . . 11
5.3 NetMigration Kolonunun Normallik Sınaması . . . 12

1 Güney Asya Nüfus ve Göç Verileri (1960-2023)

Bu veri seti, Güney Asya ülkelerinden **Afganistan**, **Bangladeş**, **Hindistan**, **Pakistan** ve **Sri Lanka**'nın **1960-2023 yılları arasındaki** nüfus ve göç verilerini içermektedir. Veri seti, bu ülkelerin demografik değişimlerini analiz etmek için güçlü bir kaynak sunar.

1.1 Sütunlar

- **Country (Ülke)**: Verinin ait olduğu ülkenin adı. Bu kolon, sayısal olduğu için çalışmaya dahil edilmemiştir.
- **Year (Yıl)**: Verinin kaydedildiği yıl.
- **Total Population (Toplam Nüfus)**: İlgili yılda ülkenin toplam nüfusu.
- **Net Migration (Net Göç)**: Göç bakiyesi (pozitif değer göç fazlasını, negatif değer göç kaybını ifade eder).

1.2 Veri Setine Erişim

Veri setine aşağıdaki bağlantı üzerinden erişebilirsiniz:
Population and Net Migration Dataset - World Bank (Kaggle)

1.3 Veri Seti Özet Bilgiler

```
##    Country               Year      total_population    net_migration
##  Length:320         Min.   :1960   Min.   :8.622e+06   Min.   :-2290411.0
##  Class :character   1st Qu.:1976   1st Qu.:1.888e+07   1st Qu.: -287381.2
##  Mode  :character   Median :1992   Median :7.270e+07   Median :  -84559.5
##                     Mean   :1992   Mean   :2.381e+08   Mean   : -174649.8
##                     3rd Qu.:2007   3rd Qu.:1.829e+08   3rd Qu.:    -840.5
##                     Max.   :2023   Max.   :1.429e+09   Max.   : 1834556.0
```

2 Veri Seti Çarpıklık Analizi

```
## Kolon: Year - Çarpıklık: 0
## Kolon: total_population - Çarpıklık: 1.890038
## Kolon: net_migration - Çarpıklık: -1.225441
```

- **Year** sütunu simetrik bir dağılım sergilemektedir.
- **Total Population** sütunu sağa çarpık bir yapıya sahiptir ve büyük değerler yoğunlaşmıştır.
- **Net Migration** sütunu sola çarpık bir yapı sergilemekte ve düşük değerlere doğru yoğunlaşma göstermektedir.



- **Year** sütunu dengeli bir dağılım sergileyerek zamanın düzgün bir şekilde kapsandığını göstermektedir.
- **total_population** sütunu sağa çarpık bir yapıya sahiptir, büyük nüfus değerlerinin belirgin şekilde yoğunlaştığı görülmektedir.
- **net_migration** sütunu ise sola çarpık bir yapı sergileyerek bazı yıllarda yoğun göç kayıplarını yansıtmaktadır.

3 Çarpıklık İçin Uygun Dönüşümün Bulunması

```
## Skewness of total_population: 1.890038

## Skewness of sqrt(total_population): 1.295641

## Skewness of (total_population)^(1/3): 1.016219

## Skewness of log(total_population): 0.3719903

## Skewness of 1/total_population: 0.9542062

## Skewness of net_migration: -1.225441

## Skewness of net_migration^2: 5.005984

## Skewness of net_migration^3: -5.643001

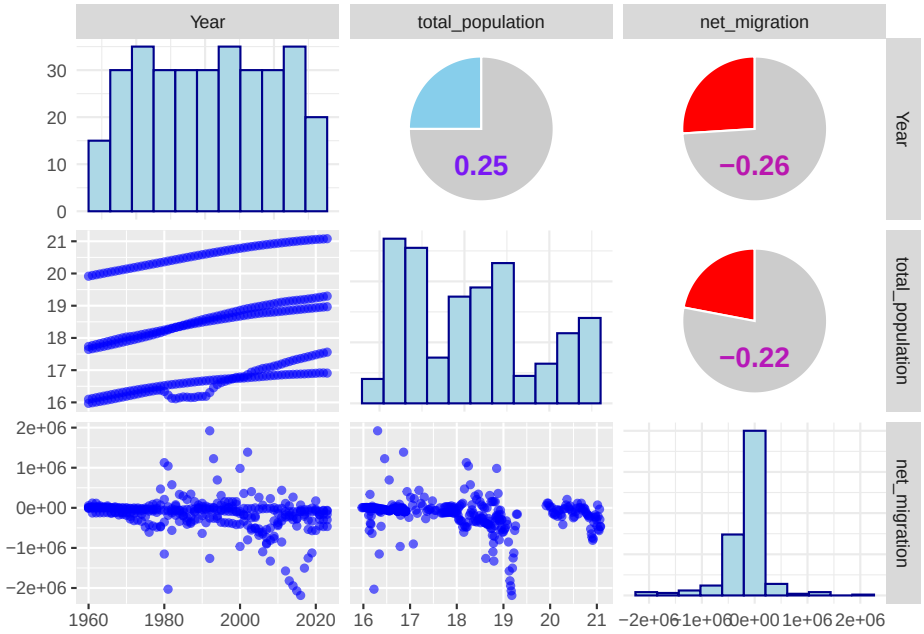
## Skewness of Yeo-Johnson transformed net_migration: -0.964005
```

- **Year** kolonu simetrik bir dağılıma sahiptir (çarpıklık: 0) ve yıllar düzgün bir şekilde kapsanmıştır.

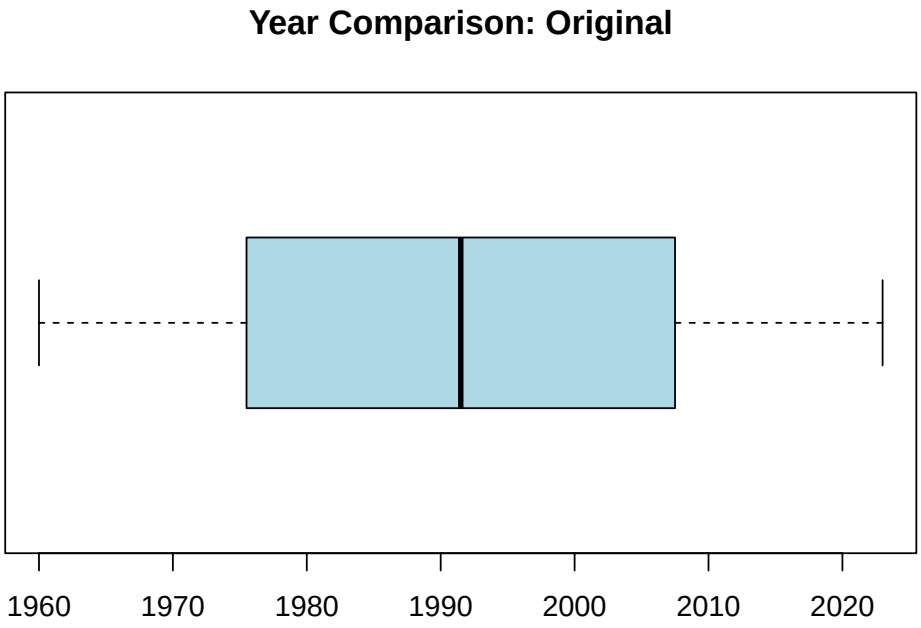
- **total_population** kolonu sağa çarpık bir yapı sergilemektedir. Log dönüşümü çarpıklığı azaltarak dağılımı simetriye yaklaştırmıştır.

- **net_migration** kolonu sola çarpık bir yapıya sahiptir. Yeo-Johnson dönüşümü çarpıklığı önemli ölçüde azaltarak daha simetrik bir dağılım sağlamıştır.

4 Dönüşüm Sonrası Veri Görselleştirmesi

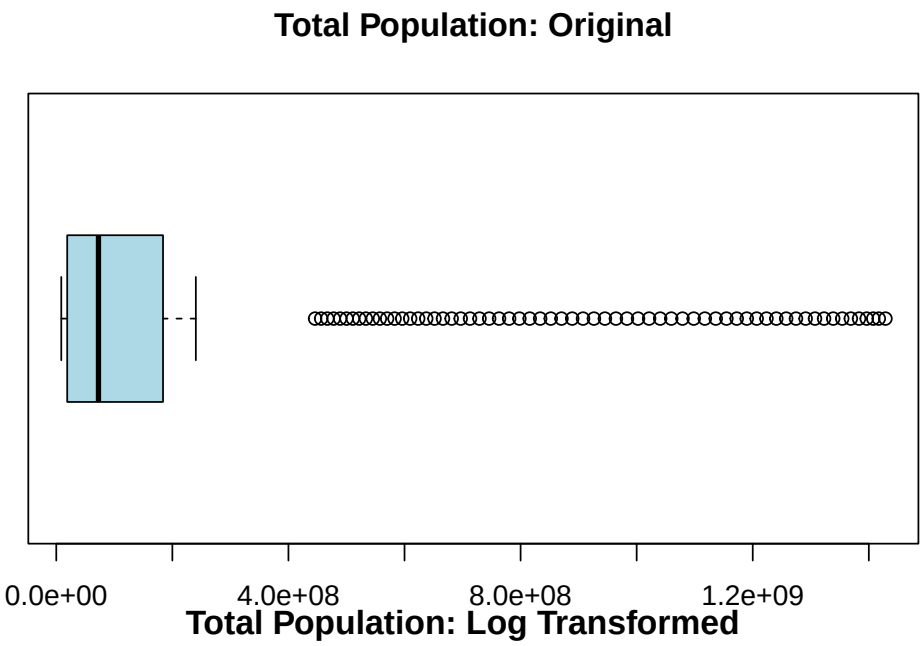


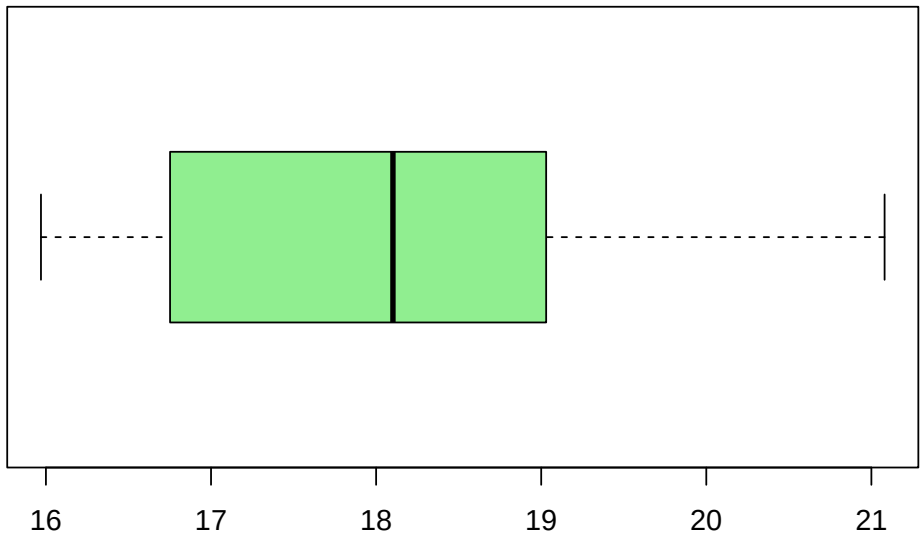
4.1 Year Kolonu



Year kolonu, her ülke için uniform dağılıma sahip olduğu için simetrik dağılıma sahiptir.

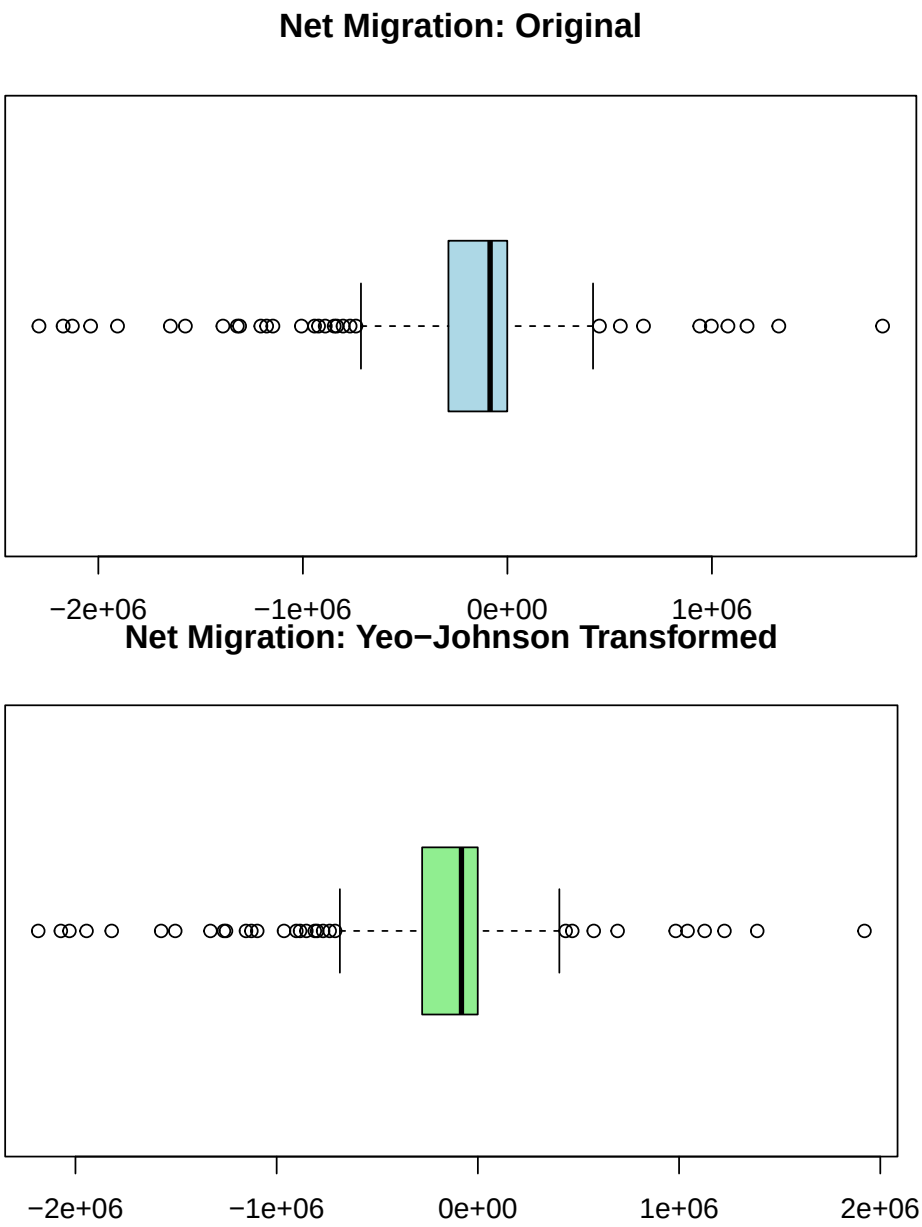
4.2 Total Population Kolonu





Sağa çarpık dağılım, Total Population log transformasyonunundan sonra azalmıştır.

4.3 Net Migration Kolonu



Net migration kolonuna yapılan Yeo-Johnson transformasyonu yapıldığında verinin bir tık daha simetrik hale geldiği gözükmüştür.

5 Goodnes of Fit Testleri

```
set.seed(42)
data_30 <- data2[sample(nrow(data2), 30), ]
data_60 <- data2[sample(nrow(data2), 60), ]
```

Veriden rastgele 30 gözlemden ve rastgele 60 gözlemden oluşan yeni veri setleri seçilmiştir.

5.1 Year Kolonunun Normallik Sınaması

```
library(nortest)  # Lilliefors, Cramer-von Mises, Anderson-Darling
library(goftest)  # Watson testi
library(stats)    # Kolmogorov-Smirnov ve Shapiro-Wilk
library(DescTools)

# Test fonksiyonunu uygulayan bir yardımcı fonksiyon
run_tests <- function(data_column) {
  ks_pval <- ks.test(data_column, "pnorm", mean(data_column), sd(data_column))$p.value
  lilliefors_pval <- lillie.test(data_column)$p.value
  cvm_pval <- cvm.test(data_column)$p.value
  ad_pval <- ad.test(data_column)$p.value
  shapiro_pval <- shapiro.test(data_column)$p.value

  return(c(ks_pval, lilliefors_pval, cvm_pval, ad_pval, shapiro_pval))
}

# Bir değişken için test sonuçlarını bir dataframe'e toplayan fonksiyon
generate_test_df <- function(data2, data_30, data_60, column_name) {
  data2_pvalues <- run_tests(data2[[column_name]])
  data30_pvalues <- run_tests(data_30[[column_name]])
  data60_pvalues <- run_tests(data_60[[column_name]])
```

```r
  # Sonuçları bir dataframe'e dönüştür
  pvalues_df <- data.frame(
    Test = c("Kolmogorov-Smirnov", "Lilliefors", "Cramer-von Mises", "Anderson-Darling"
    Data30 = data30_pvalues,
    Data60 = data60_pvalues,
    DataFull = data2_pvalues
  )

  return(pvalues_df)
}

# Listeyi oluştur
pvalues_list <- list(
  Year = generate_test_df(data2, data_30, data_60, "Year"),
  TotalPopulation = generate_test_df(data2, data_30, data_60, "total_population"),
  NetMigration = generate_test_df(data2, data_30, data_60, "net_migration")
)

# Listeyi görüntüle
print(pvalues_list[1])
```

```
## $Year
##                 Test    Data30      Data60     DataFull
## 1 Kolmogorov-Smirnov 0.9687990 0.647472282 1.378532e-01
## 2         Lilliefors 0.7763109 0.192730702 2.599231e-03
## 3   Cramer-von Mises 0.0000000 0.000000000 0.000000e+00
## 4   Anderson-Darling 0.0000200 0.000010000 1.875000e-06
## 5       Shapiro-Wilk 0.1180750 0.007461506 1.819763e-08
```

H (Null Hipotezi): Veri normal dağılıma uygundur ($p \geq 0.05$).

- **Kolmogorov-Smirnov**:
  - Data30 ($p = 0.9688$) ve Data60 ($p = 0.6475$) için H reddedilemez.
  - DataFull ($p = 0.1379$) normalliğe sınırda uygundur.

- **Lilliefors**:
  - Data30 ($p = 0.7763$) ve Data60 ($p = 0.1927$) için H reddedilemez.
  - DataFull ($p = 0.0026$) için H reddedilir.
- **Cramer-von Mises**:
  - Tüm gruplar için ($p = 0.0000$) H reddedilir, veri normal değildir.
- **Anderson-Darling**:
  - Tüm gruplar için ($p = 0.00002, 0.00001, 1.87e-6$) H reddedilir.
- **Shapiro-Wilk**:
  - Data30 ($p = 0.1181$) için H reddedilemez.
  - Data60 ($p = 0.0075$) ve DataFull ($p = 1.82e-8$) için H reddedilir.

Sonuç: Data30, normal dağılıma en yakın gruptur. DataFull belirgin şekilde normal değildir.

5.2 TotalPopulation Kolonunun Normallik Sınaması

```
print(pvalues_list[2])
```

```
## $TotalPopulation
##                 Test      Data30      Data60     DataFull
## 1 Kolmogorov-Smirnov 0.397849563 0.197858462 6.920449e-05
## 2         Lilliefors 0.053096097 0.007552886 1.757722e-13
## 3   Cramer-von Mises 0.000000000 0.000000000 0.000000e+00
## 4   Anderson-Darling 0.000020000 0.000010000 1.875000e-06
## 5       Shapiro-Wilk 0.009446554 0.001213316 3.450894e-11
```

H (Null Hipotezi): Veri normal dağılıma uygundur ($p \geq 0.05$).

- **Kolmogorov-Smirnov**:
  - Data30 ($p = 0.3978$) için H reddedilemez.
  - Data60 ($p = 0.1979$) için H reddedilemez.
  - DataFull ($p = 6.92e-5$) için H reddedilir.
- **Lilliefors**:
  - Data30 ($p = 0.0531$) için H sınırda reddedilemez.

  - Data60 ($p = 0.0076$) ve DataFull ($p = 1.76e-13$) için H reddedilir.
- **Cramer-von Mises**:
  - Tüm gruplar için ($p = 0.0000$) H reddedilir, veri normal değildir.
- **Anderson-Darling**:
  - Tüm gruplar için ($p = 0.00002, 0.00001, 1.87e-6$) H reddedilir.
- **Shapiro-Wilk**:
  - Data30 ($p = 0.0094$) için H reddedilir.
  - Data60 ($p = 0.0012$) ve DataFull ($p = 3.45e-11$) için H reddedilir.

Sonuç: Data30 ve Data60 normalliğe nispeten daha yakınken, DataFull açıkça normal dağılıma uygun değildir. Ancak Data30 için bile bazı testler normalliği reddetmiştir.

5.3 NetMigration Kolonunun Normallik Sınaması

```
print(pvalues_list[3])
```

```
## $NetMigration
##                 Test     Data30       Data60     DataFull
## 1 Kolmogorov-Smirnov 0.20647980 1.874570e-02 3.184868e-09
## 2         Lilliefors 0.00780416 6.542483e-06 1.477251e-27
## 3   Cramer-von Mises 0.00000000 0.000000e+00 0.000000e+00
## 4   Anderson-Darling 0.00002000 1.000000e-05 1.875000e-06
## 5       Shapiro-Wilk 0.03722233 1.620803e-08 8.459086e-20
```

H (Null Hipotezi): Veri normal dağılıma uygundur ($p \geq 0.05$).

- **Kolmogorov-Smirnov**:
  - Data30 ($p = 0.2065$) için H reddedilemez.
  - Data60 ($p = 0.0187$) ve DataFull ($p = 3.18e-9$) için H reddedilir.
- **Lilliefors**:
  - Data30 ($p = 0.0078$), Data60 ($p = 6.54e-6$) ve DataFull ($p =$

$1.48e-27$) için H reddedilir.

- **Cramer-von Mises**:
  - Tüm gruplar için ($p = 0.0000$) H reddedilir, veri normal değildir.
- **Anderson-Darling**:
  - Tüm gruplar için ($p = 0.00002, 1.00e-5, 1.87e-6$) H reddedilir.
- **Shapiro-Wilk**:
  - Data30 ($p = 0.0372$) için H reddedilir.
  - Data60 ($p = 1.62e-8$) ve DataFull ($p = 8.46e-20$) için H reddedilir.

Sonuç: Data30, diğer gruplara göre normalliğe daha yakındır. Data60 ve DataFull belirgin şekilde normal dağılıma uygun değildir.